

ФЕДЕРАЛЬНОЕ ГОСУДАРСТВЕННОЕ БЮДЖЕТНОЕ
ОБРАЗОВАТЕЛЬНОЕ УЧРЕЖДЕНИЕ ВЫСШЕГО ОБРАЗОВАНИЯ
«САНКТ-ПЕТЕРБУРГСКИЙ ГОСУДАРСТВЕННЫЙ УНИВЕРСИТЕТ»
(СПбГУ)

Образовательная программа бакалавриата «Науки о данных»



Отчёт по практике
«Учебная практика (проектно-технологическая практика)»

Выполнил студент 2 курса бакалавриата
(группа 22.Б05-мкн)


Михеев Артём Антонович

Научный руководитель:
д.ф.-м.н. Тискин Александр Владимирович

Санкт-Петербург
2024

Введение.

Коды исправляющие ошибки (или коды коррекции ошибок) - это специальные методы в области информационных технологий, которые позволяют обнаруживать и исправлять ошибки, возникающие при передаче данных через шумные каналы связи или при хранении информации на ненадёжных носителях. Для этого при записи (передаче) в полезные данные добавляют специальным образом структурированную *избыточную* информацию, а при чтении (приеме) её используют для того, чтобы обнаружить или исправить ошибки. Естественно, что число ошибок, которое можно исправить, ограничено и зависит от конкретного применяемого кода.



$$efficiency = \frac{|k|}{|n|}$$


Если исходные

k бит код оставляет неизменными, и добавляет

$n - k$ *проверочных*, такой код называется *систематическим*, иначе *несистематическим*.


Битовые данные длины k представляются двоичным кубом B^k

Расстояние Хэмминга: $d_H(\mathbf{x}, \mathbf{y}) = |\{i \mid x_i \neq y_i\}|$



Лемма: кодирование $f : B^k \rightarrow B^n$ с исправлением e ошибок возможно тогда и только тогда, когда в B^n найдется B^k шаров радиуса e , не имеющих общих точек. (Центры этих шаров будут кодами).

Тогда расстояние между центрами $2e + 1$, а если только обнаруживаем ошибки $e + 1$.



Исправлять 1 ошибку можно утроением каждого бита, и декодировать, сопоставляя тройке бит, встречающийся дважды. Но $\text{efficiency} = 3$ будет медленно. Однако удвоения не хватит, так как расстояние между 00 и 11 равно 2, и 01 может быть получено изменением обоих кодов.

M - число шаров радиуса 1 в B^n . Всего вершин 2^n , а в одном шаре $n + 1$ вершина. Тогда справедливо неравенство:

$$M \leq \frac{2^n}{n + 1}$$

Линейный код, код Хэмминга

Линейный (блоковый) код — такой код, что множество его *кодовых слов* образует

k -мерное линейное подпространство в n -мерном линейном пространстве, изоморфное пространству n -битных векторов. Над полем F_2 .

Тогда существует порождающая матрица G , и матрица проверки H .

$a = Gv^T$ - код, и для любого кода выполнено $Hv^T = 0$. Если код изменили, то результат

Hv^T - синдром (вектор).

Пример кода, исправляющего 2 ошибки (расстояние между кодами $2e + 1 = 3$)

$$(x_1, x_2, \dots, x_k) \mapsto (x_1, x_2, \dots, x_k, x_1, x_2, \dots, x_k, x_1 \oplus x_2 \oplus \dots \oplus x_k)$$

$$G = \begin{pmatrix} I_k \\ I_k \\ v \end{pmatrix}, \text{ } v - \text{ строка из единиц.}$$

Код Хэмминга - Линейный код, может обнаруживать и исправлять одиночные ошибки в передаваемых данных. Это достигается путем добавления дополнительных контрольных битов к исходному сообщению. Для $n = 2^s - 1$, B^n заполняется 2^{n-s} шарами радиуса 1.

s - контрольных битов, и $n - s$ содержательных.

Контрольные биты подбираются, чтобы синдром проверочной матрицы H равнялся 0.

$$H = \begin{bmatrix} 0 & 0 & 0 & 1 & 1 & 1 & 1 \\ 0 & 1 & 1 & 0 & 0 & 1 & 1 \\ 1 & 0 & 1 & 0 & 1 & 0 & 1 \end{bmatrix}.$$

Их всегда можно подобрать, они стоят на местах 2^i , и мы знаем результат суммы столбцов на содержательных местах.

После изменения одного бита, мы получаем синдром, равный столбцу H , номер которого и есть номер измененного бита.

Код Хэмминга широко используется в цифровых системах связи, таких как Ethernet, а также в памяти компьютеров, где важно обеспечить целостность хранящихся данных.

Связь k/n , e/n . График.

Код хэмминга при $e/n \rightarrow 0$, $k/n \rightarrow 1$

Какую часть ошибок можно исправить, и при каком efficiency.

$$2e + 1 \leq \max d(x, y) = n$$

$$\frac{e}{n} \leq 0.5$$

$size_e$ - размер шара радиуса e в B^n


$$1 + \binom{n}{1} + \binom{n}{2} + \dots + \binom{n}{e} \approx \binom{n}{e} = 2^{n * H(e/n)}$$

$$H(x) = x \log \frac{1}{x} + (1 - x) \log \frac{1}{1 - x}$$

$$2^k * size_e \leq 2^n, \quad k/n + H(e/n) \leq 1$$

Оценка Варшамова-Гильберта.


Жадно заполняем B^n точками на расстояние $d = 2e + 1$.



Тогда $2^k * size_{2e} \geq 2^n$, $k/n + H(2e/n) \geq 2^n$

Рассмотрим $0.25 \leq e/n \leq 0.5$. Коды должны отличаться в 51%.

Понятно, что при маленьком кол-ве кодируемых слов это возможно, например для 0.25 при $k = 3$.



Но мы рассматриваем $n \rightarrow \infty$.


Количество кодируемых слов будет ограничено независимо от n .

0 заменим -1 и рассмотрим скалярное произведение

$$-1 \leq \frac{\sum_i x_i \cdot y_i}{n} \leq 1 \quad \begin{cases} (u_i, u_i) = 1 \\ (u_i, u_j) \leq -0.02 \end{cases}$$

Распишем $(u_1 + \dots + u_k, u_1 + \dots + u_k) \geq 0$, получим $0.02k(k-1) \leq k$, $k \leq 51$

Получили график. T1 - есть коды, T3 - нет кодов, T2 - неизвестно.



Код Рида - Соломона.

Используется для большого алфавита. $0, 1, \dots, q - 1$, где q простое (или степень двойки), конечное поле F_q . Теперь рассматриваем не булев куб, а $f : \{0, 1, \dots, q - 1\}^k \rightarrow \{0, 1, \dots, q - 1\}^n$

Расстояние - число различных символов и расстояние между кодами должно быть $2e + 1$

Мы сопоставляем k символам многочлен над полем F_q .

$$a_0, a_1, \dots, a_{k-1} \rightarrow A(x) = a_0 + a_1x + a_2x^2 + \dots + a_{k-1}x^{k-1}$$


И в качестве кода берём значения в n точках $\alpha_1, \dots, \alpha_n$ ($n \leq q$).

Лемма: Многочлен степени меньше k имеет меньше k корней.

Поэтому расстояние между полученными кодами больше $n - k$, иначе многочлены равны и изначальные символы тоже.

И тогда мы можем исправить $e = (n - k)/2$ ошибок. Увеличение кода линейно от числа ошибок.

Это оптимальное кодирование, так как существуют коды первых $k-1$ символов которых совпадают и поэтому расстояние всегда меньше или



Декодирование.

$A(x), \deg A \leq k$, A' - измененный значения

Утверждение: Существует многочлен $Q(x), \deg Q = e$, и многочлен

$P(x), \deg P \leq k + e$, что $P = A'Q$ (равенство в $\alpha_1, \dots, \alpha_n$.)

Их коэффициенты - решение простой линейной системы из n уравнений с $k + e$ неизвестными.

$$A'(\alpha_i)Q(\alpha_i) = P(\alpha_i) = ? A(\alpha_i)Q(\alpha_i)$$

Пусть $AQ \neq P$, тогда справа равенство меньше чем $k + e$ и больше или равно, чем $n - e$. Что верно при $e > (n - k)/2$.

Осталось столбиком поделить $P(x)$ на $Q(x)$ и получить коэффициенты исходного $A(x)$ и сами символы.



Кода Рида-Соломона применяются в системах хранения данных, таких как жёсткие диски, флеш-накопители и оптические диски, для обеспечения целостности и надежности хранения информации.

Дальше можно комбинировать, получая каскадные коды.

Каскадные коды объединяют два или более кода в последовательную структуру, где один код обрабатывает данные, а затем выходные данные этого кода поступают на вход следующего кода. Это позволяет использовать преимущества каждого из кодов, обеспечивая более высокую степень защиты от ошибок.

Еще один раздел LDPC коды. Их матрицы проверки на четность должны быть разреженными, то есть нулей в них должно быть значительно больше, чем чего-либо другого. Удобно представлять графом Таннера.

$$\mathbf{H}_{M \times N} = \begin{pmatrix} 1 & 1 & 0 & 1 & 0 & 0 & 1 & 0 & 0 & 0 \\ 0 & 1 & 1 & 0 & 1 & 0 & 0 & 1 & 0 & 0 \\ 1 & 0 & 0 & 0 & 1 & 1 & 0 & 0 & 1 & 0 \\ 0 & 0 & 1 & 1 & 0 & 1 & 0 & 0 & 0 & 1 \end{pmatrix}$$



Итог:

Узнал различные алгоритмы с исправлением ошибок, актуальность данных кодов и использование в сферах (цифровые коммуникационные системы, 5G)
реализовал некоторые.

Ссылка на репозиторий: <https://github.com/mikhart7/practise>

Используемые материалы:

Лекции Александра Шень - <https://www.lektorium.tv/node/31749>